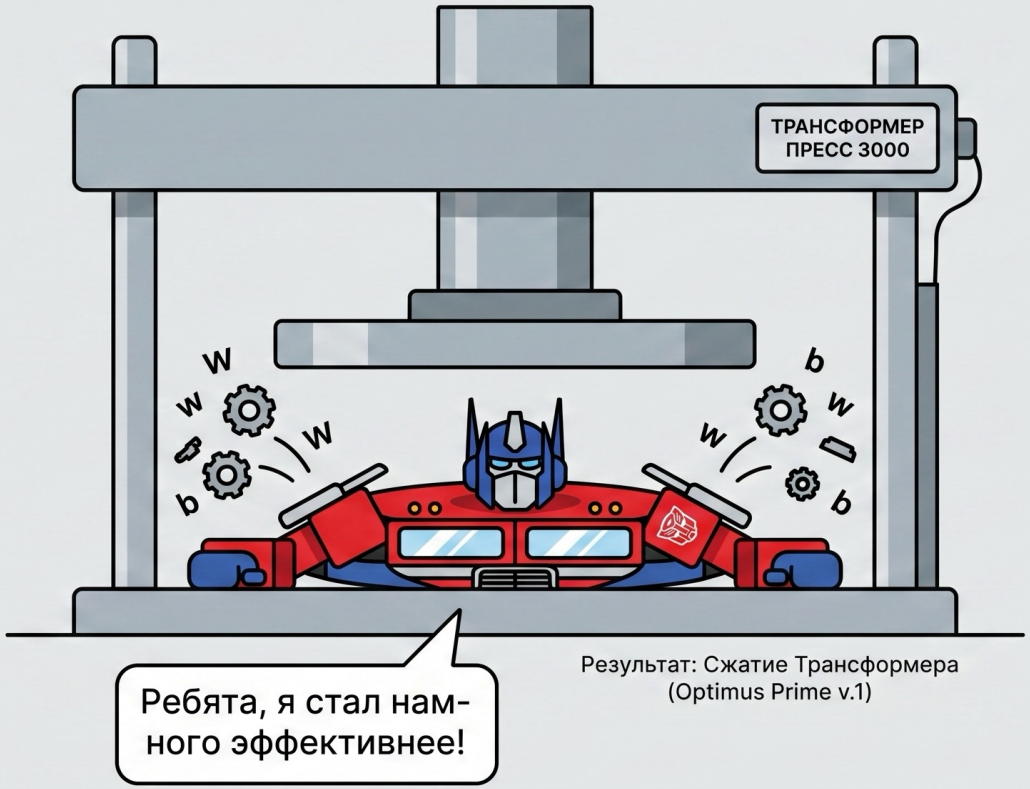
Сжатие моделей

Демьянко Андрей
Завьялов Глеб
Соловьев Александр
Перельман Михаил
Харисов Богдан
Царин Илья

Студкемп по CV

Яндекс Образование

СЖАТИЕ МОДЕЛЕЙ



Результат: Сжатие Трансформера
(Optimus Prime v.1)

Демьянко Андрей
Завьялов Глеб
Соловьев Александр
Перельман Михаил
Харисов Богдан
Царин Илья

Студкемп по CV

Яндекс Образование

01



Цель и задачи проекта

Уменьшить gap в качестве между моделями разного размера

Задачи

01

Проанализировать научные статьи по теме Knowledge Distillation, найти самые новые методы

02

Сформулировать гипотезы и провести эксперименты. Сделать выводы и найти лучшие методы дистилляции

03

Снимать метрики с моделей в реальном окружении: конвертация в ONNX, замер времени и качества работы

02



Ход работы

Лучшая метрика прироста

Сократили gap на

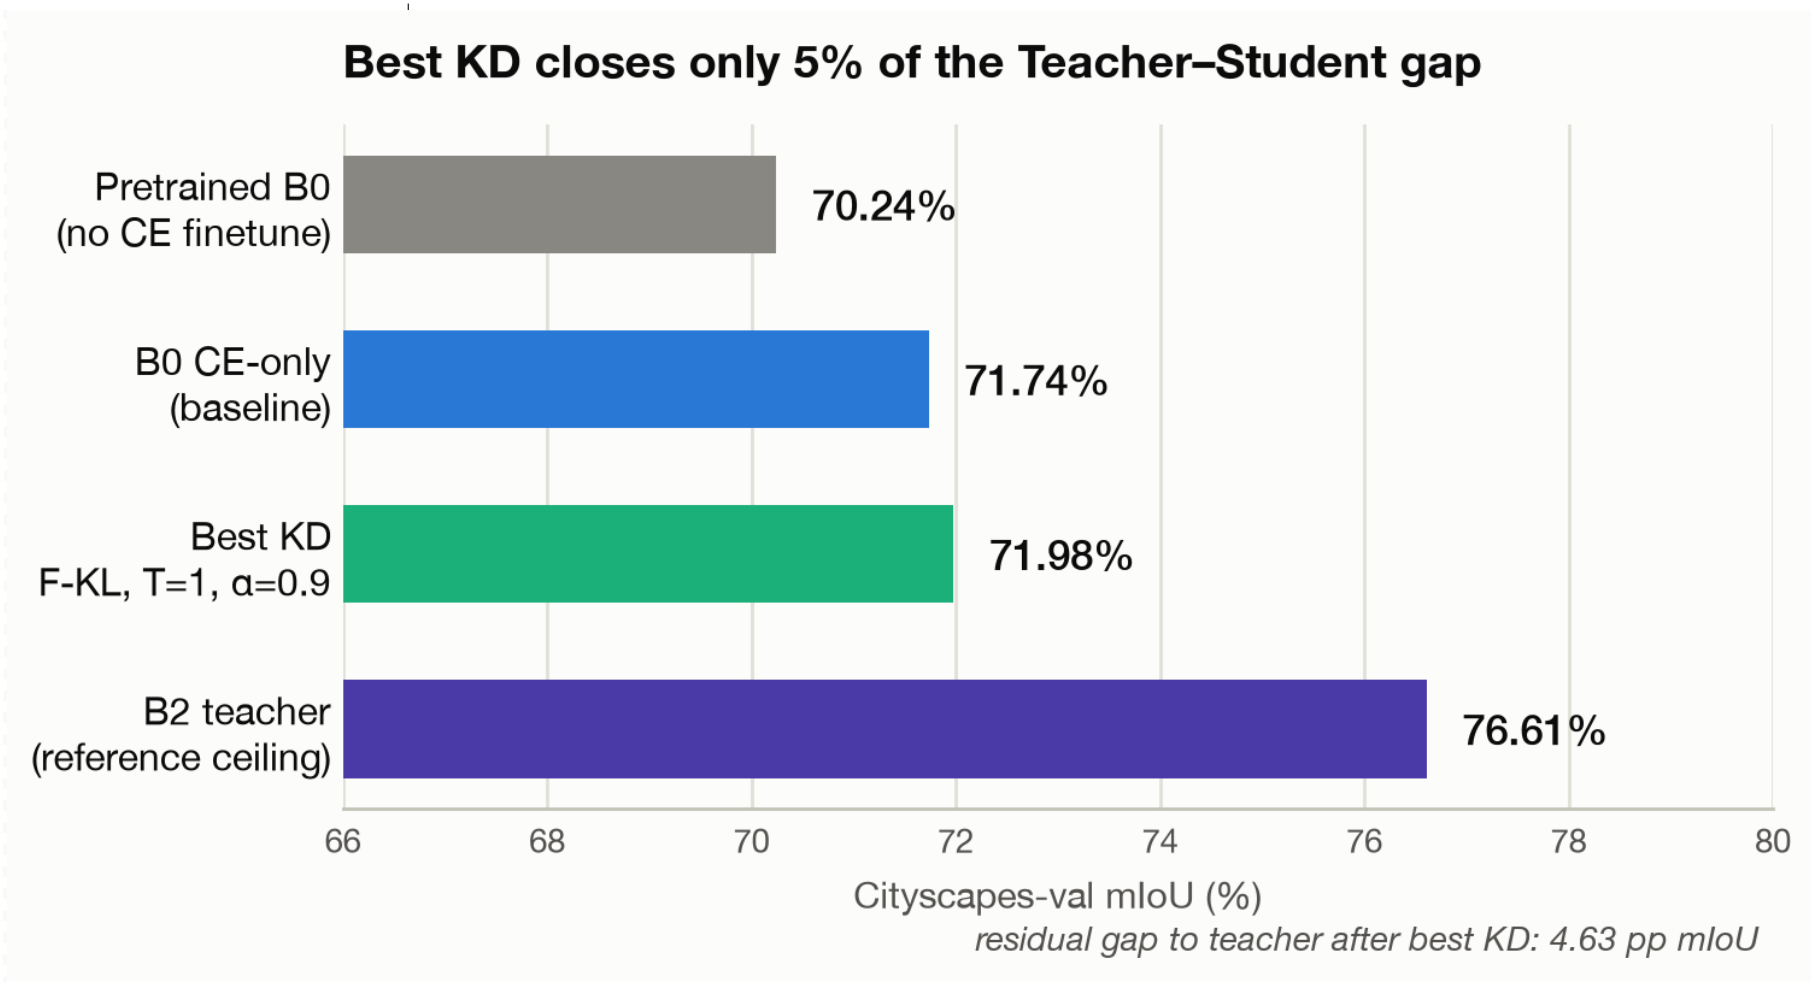
- **27.3%** в задаче сегментации
- **97%** в задаче предсказания карты глубины



Получили прирост

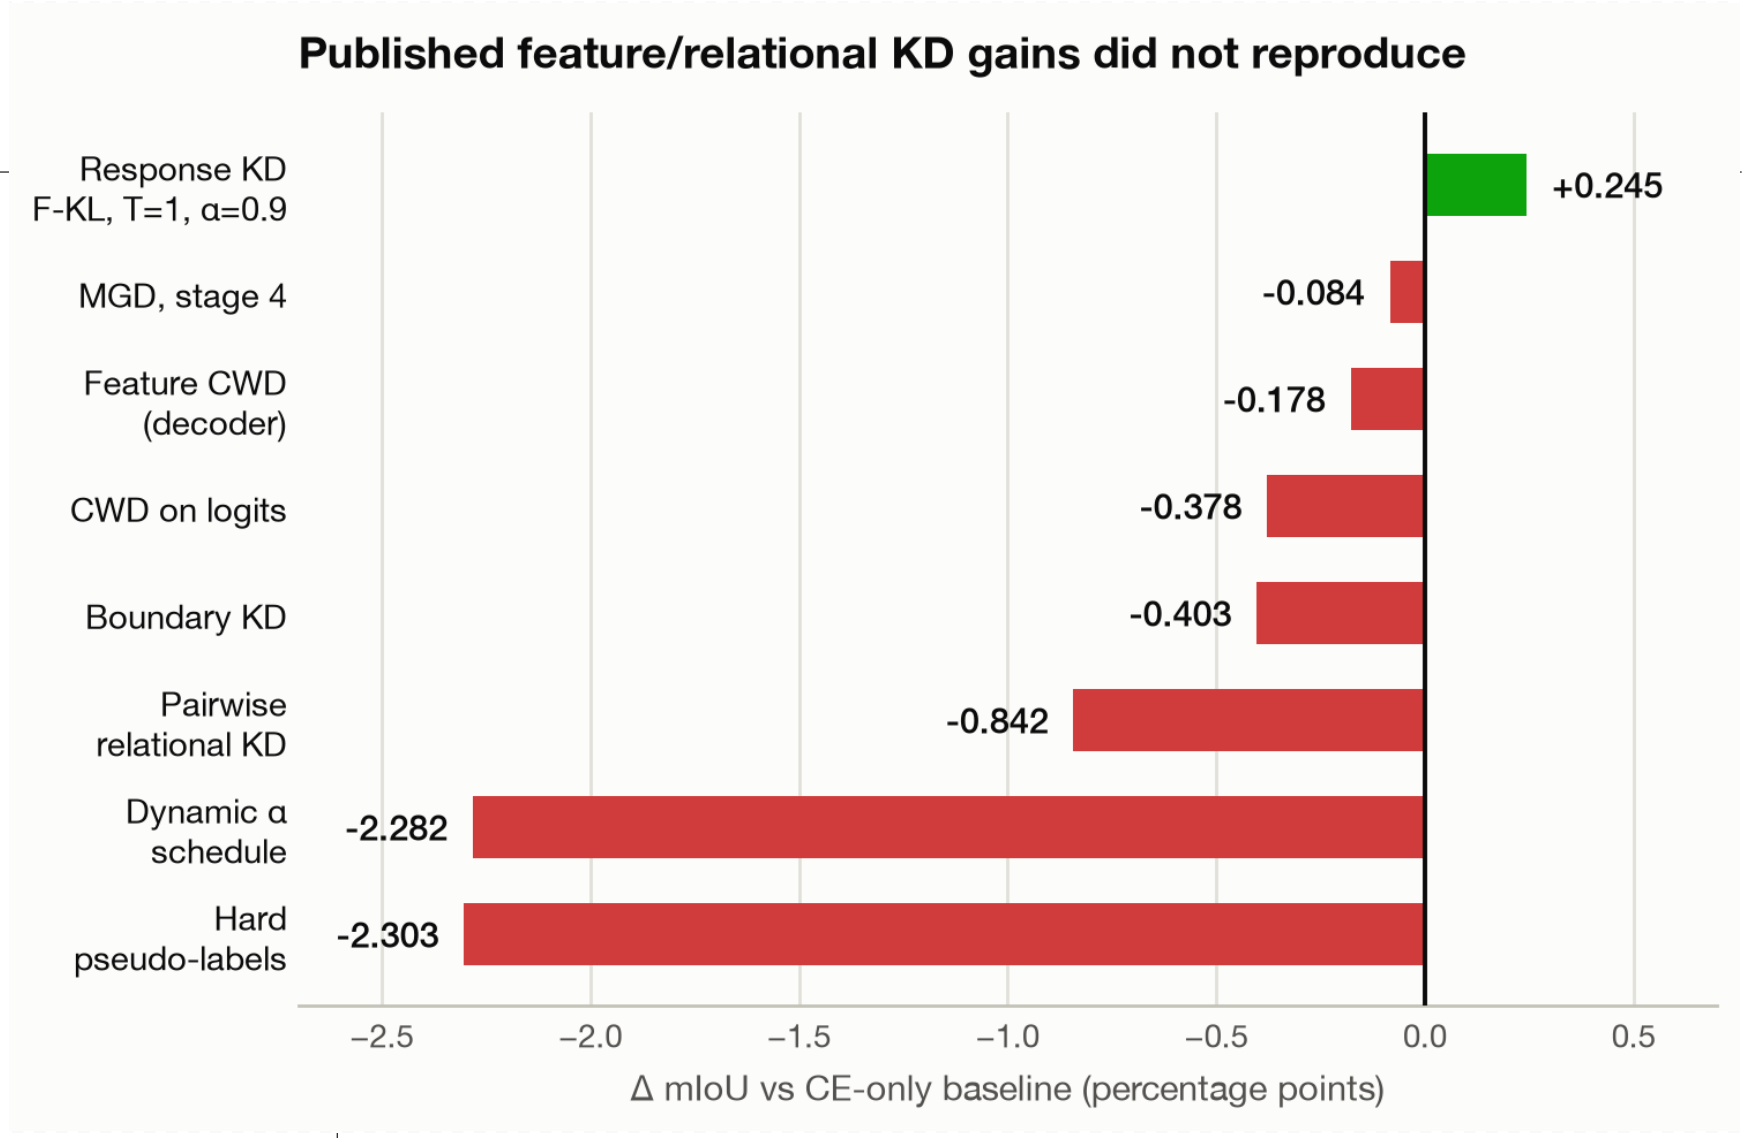
Сегментация

- Провели подбор гиперпараметров
- Провели простую дистилляцию
- Получили прирост



Сегментация

- Нашли самые цитируемые статьи
- Провели 30+ экспериментов
- Лучше всего работает самый простой метод

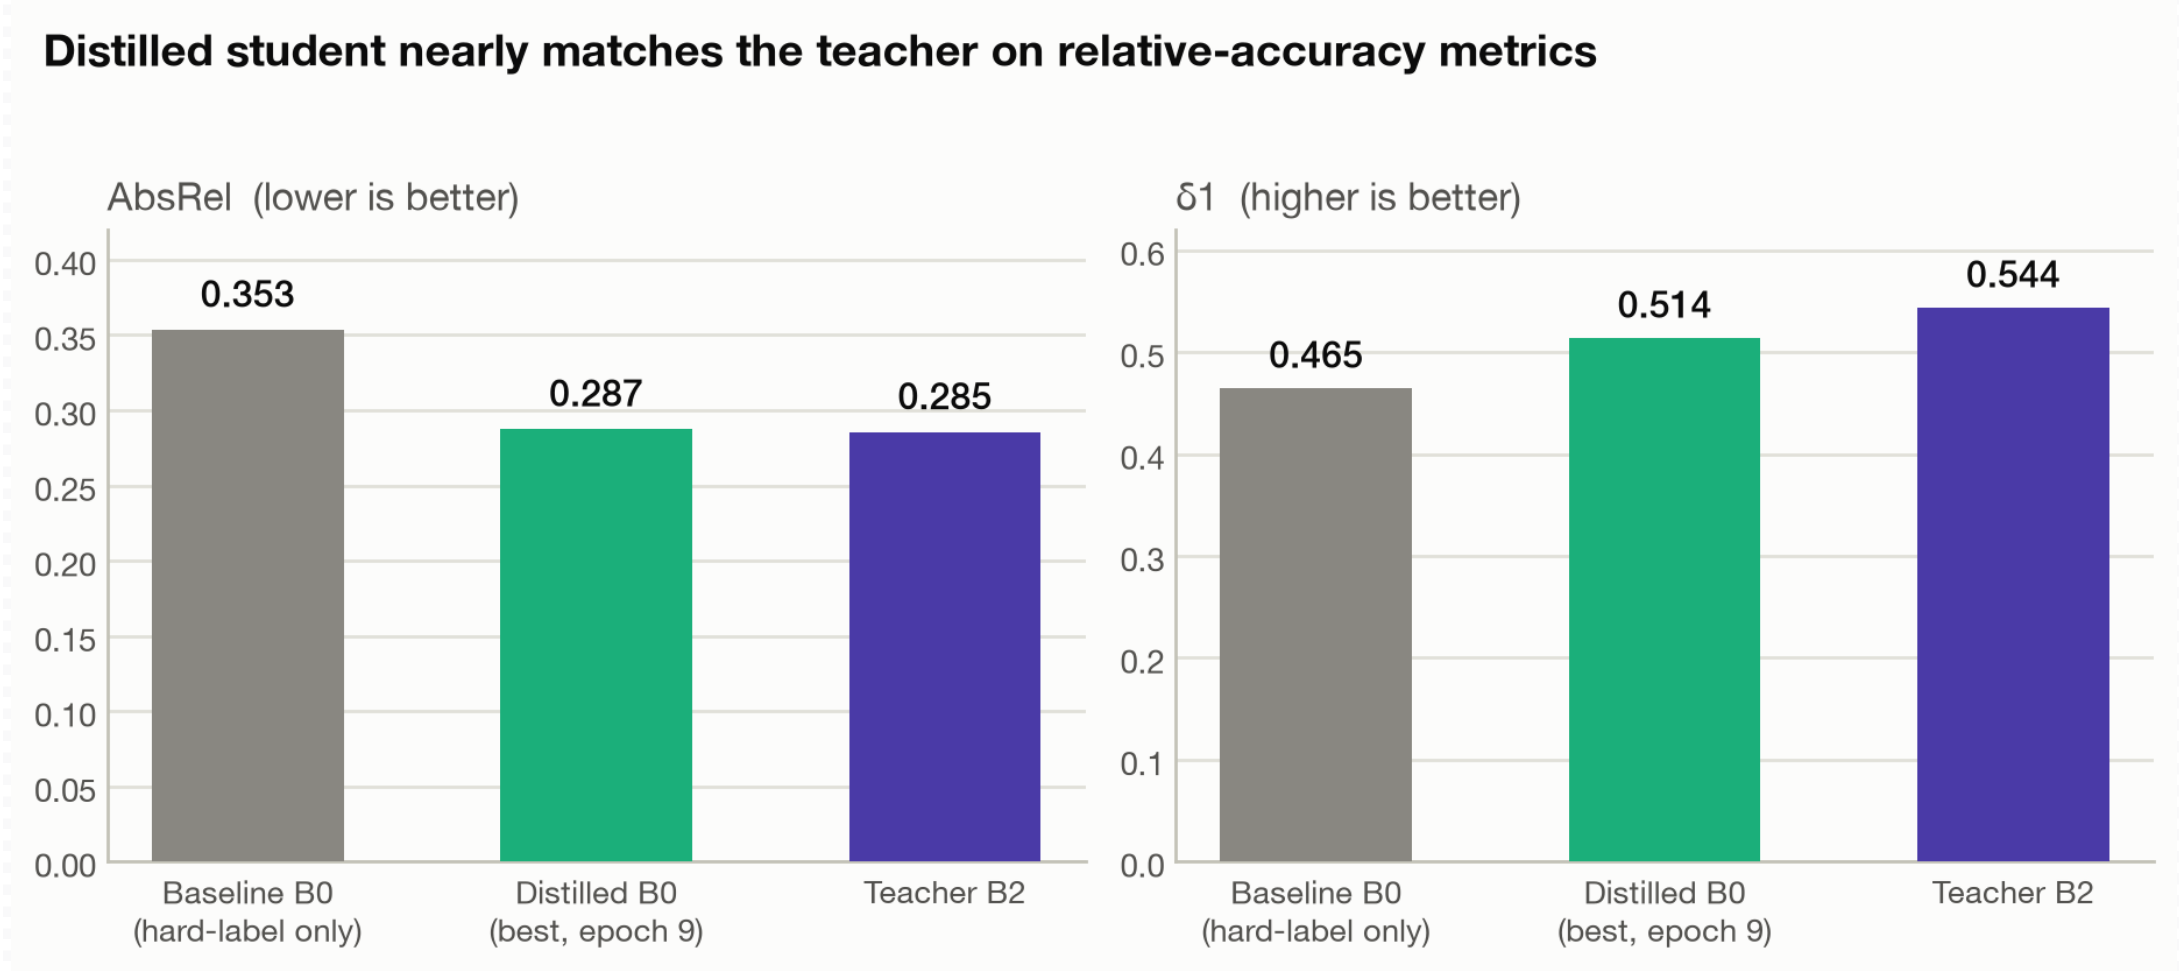


Сегментация



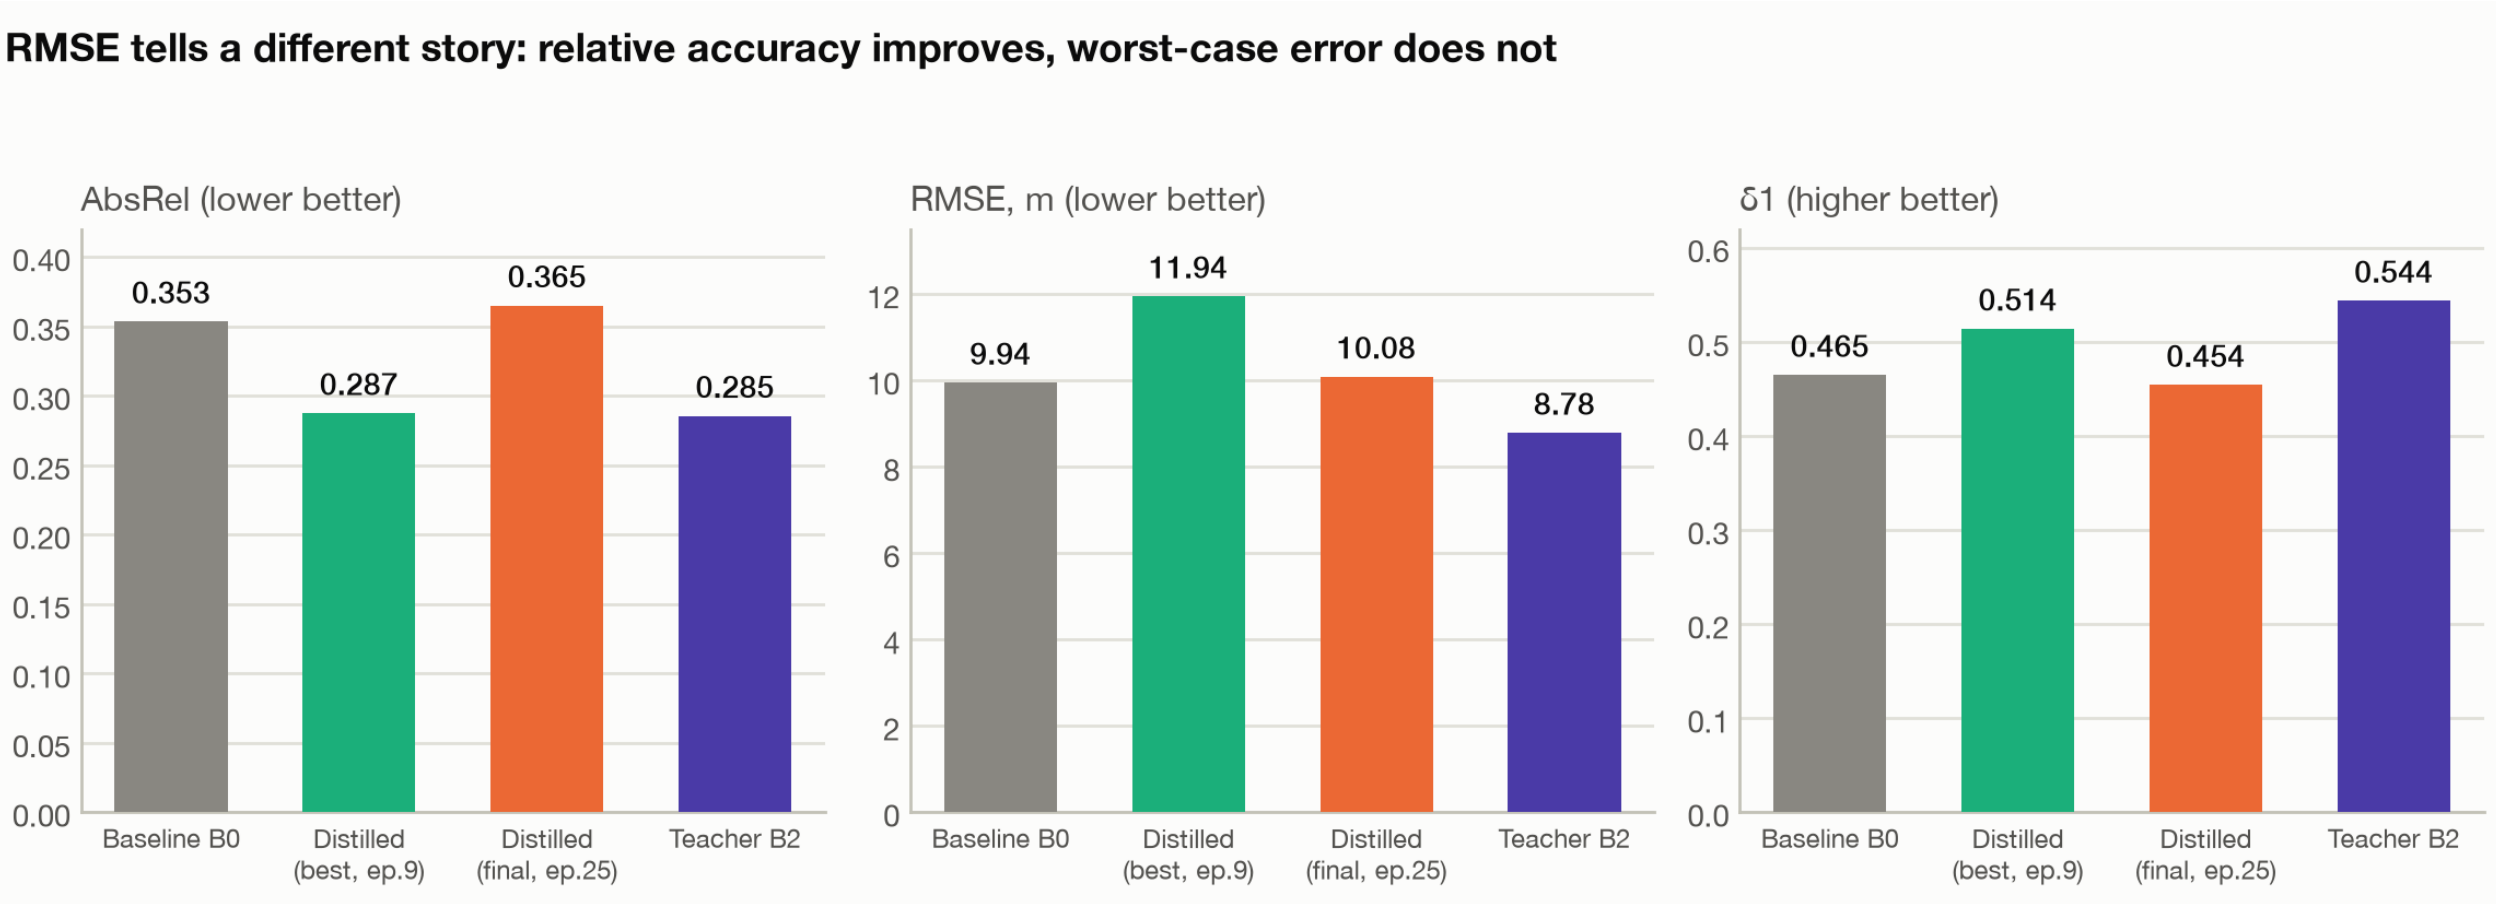
Карта глубины

- Претрейна на карту глубины не было –> учили сами
- Дистилляция только по учителю

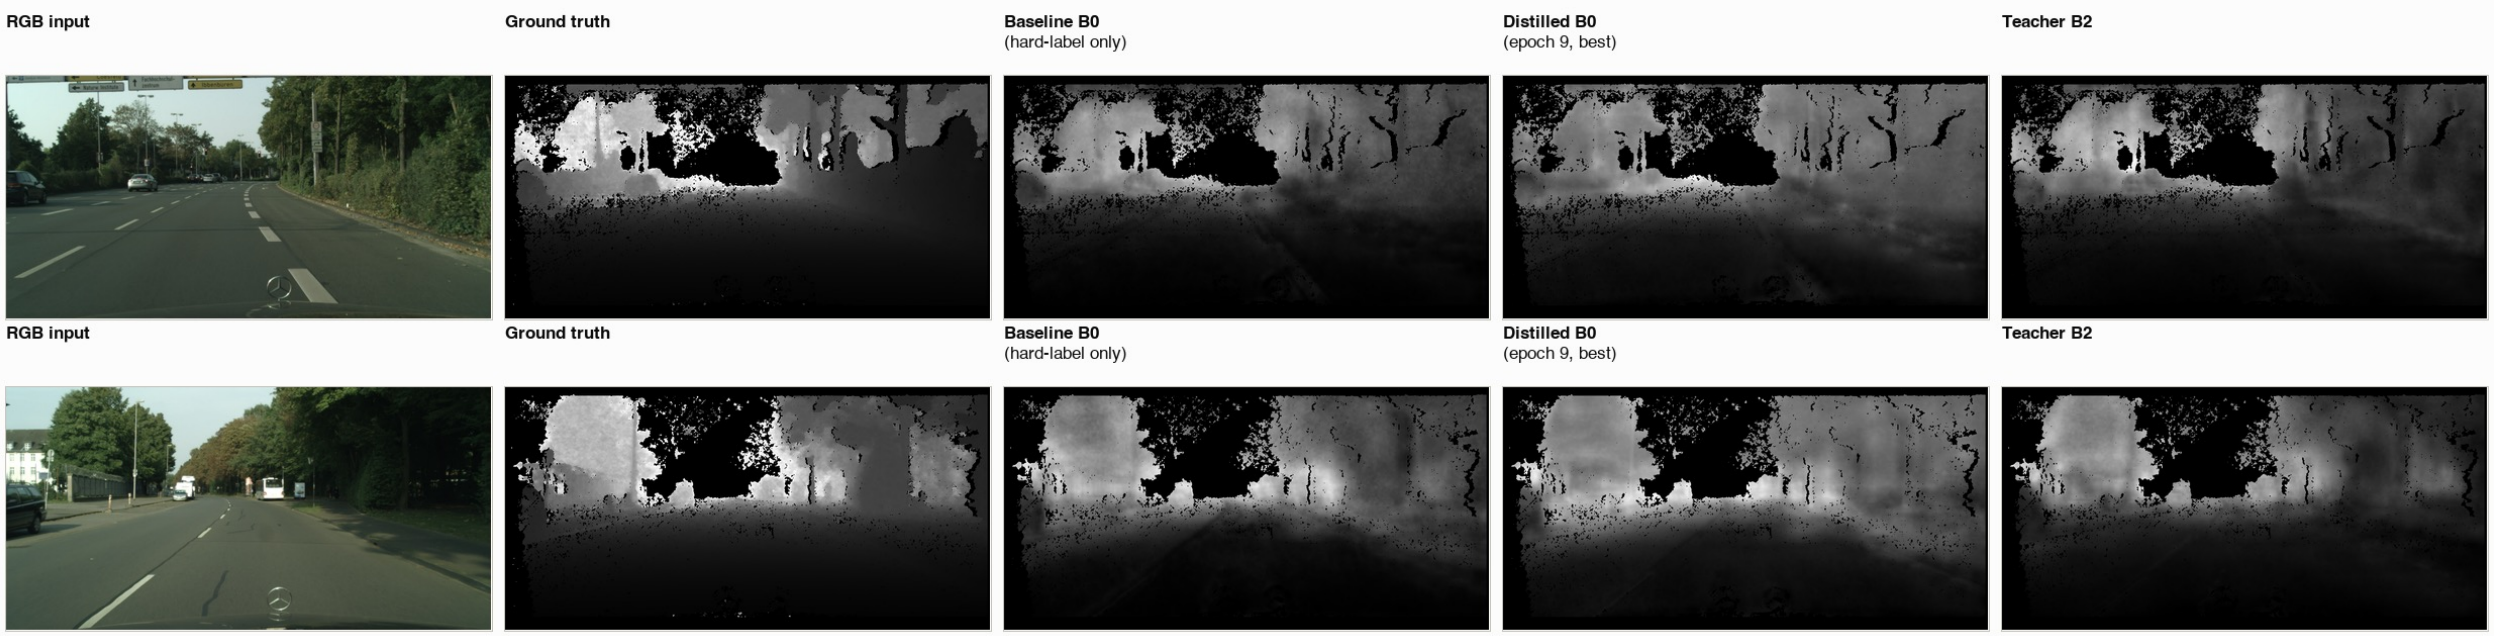


Карта глубины

- Картинки странные
- Метрики говорят разное



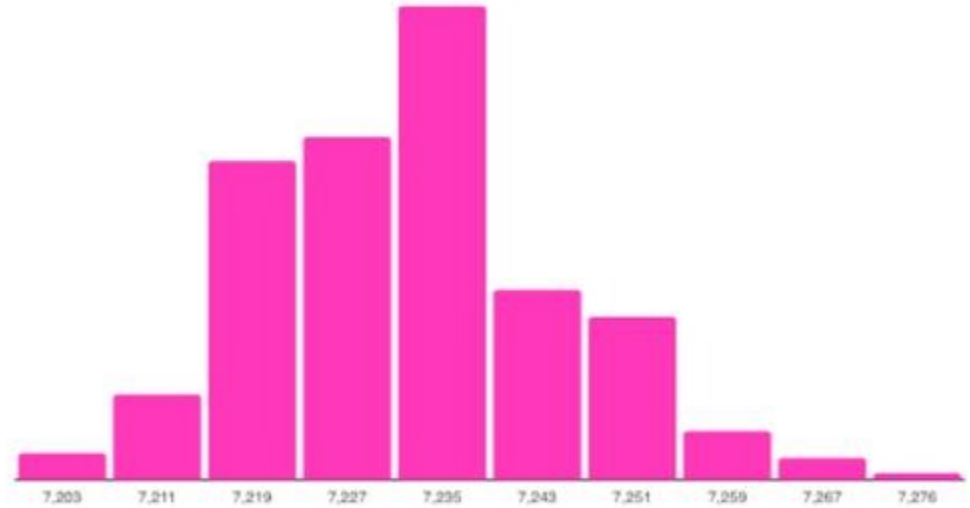
Карта глубины



TensorRT на V100

Качество сохранилось

- mIoU: 0,65186194 → 0,65186230
- Δ: 0,00000036
- 100% совпадение карт классов



7,23 мс

p50 latency · p99 7,26 мс

171,9

изображений/с · 8 параллельных потоков

Вывод

Что мы выяснили

- В наших экспериментах сложные и идейные методы не показали прироста качества
- Чем меньше разница в качестве моделей, тем лучше результат
- Дистилляция без якоря дает нестабильный результат
- Разные метрики по-разному оценивают одного студента
- Деплой удался

